

# Fehler 1. und 2. Art Vertrauensintervalle

Peter Büchel

HSLU I

Stat: Block 07

# Fehler Hypothesentest

- Nullhypothese bei Hypothesentest ist richtig (was aber nicht bekannt)
- Machen  $n$  Messungen um Hypothesentest zu überprüfen
- Messungen ergeben extreme Werte
- Durchschnitt  $\bar{x}_n$  liegt im Verwerfungsbereich: Nullhypothese wird verworfen
- Es wurde ein Fehler gemacht: Nullhypothese wird verworfen, obwohl Nullhypothese richtig ist
- Hypothesentest macht keine absolute Aussage, sondern sagt nur das Aussage sehr wahrscheinlich stimmt ( $p$ -Wert nahe bei 0)
- Unsicherheit bleibt

# Fehler Hypothesentest


- Schema:

| <b>Entscheidung</b><br><b>Wahrheit</b> | $H_0$         | $H_A$         |
|--|---------------|---------------|
| $H_0$                                  | ✓             | Fehler 1. Art |
| $H_A$                                  | Fehler 2. Art | ✓             |

- Entscheidung für  $H_0$ , aber  $H_A$  wäre richtig  $\rightarrow$  Fehler 2. Art
- Entscheidung für  $H_A$ , aber  $H_0$  wäre richtig  $\rightarrow$  Fehler 1. Art


# Fehler 1. Art

- Entscheidung für  $H_A$ , aber  $H_0$  wäre richtig  $\rightarrow$  Fehler 1. Art
- Entspricht gerade Signifikanzniveau
- Skizze:  
y



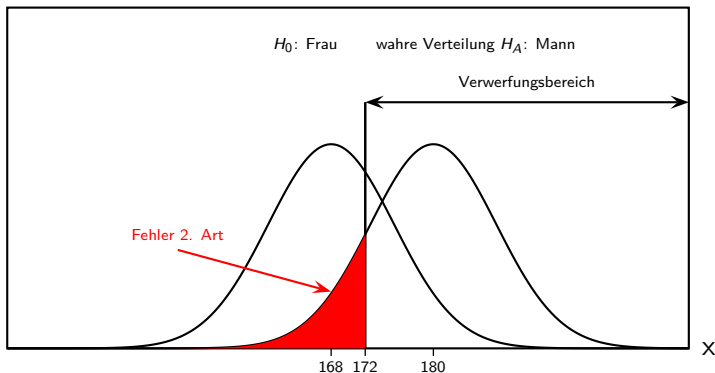
# Macht

- $H_A$  wird angenommen und  $H_A$  richtig  $\rightarrow$  das was wir wollen
- Der wahre Parameter für  $H_A$  muss bekannt sein  $\rightarrow$  hier  $\mu_A = 180$
- Skizze:



## Fehler 2. Art

- Entscheidung für  $H_0$ , aber  $H_A$  wäre richtig  $\rightarrow$  Fehler 2. Art
- Der wahre Parameter für  $H_A$  muss bekannt sein  $\rightarrow$  hier  $\mu_A = 180$
- Fehler 2. Art =  $1 - \text{Macht}$
- Skizze:



# Welche Fehlerart ist wichtiger?


- Fehler 1. Art hat traditionell mehr Gewicht als Fehler 2. Art
- Wissenschaftler arbeiten genau und haben Angst, einen Humbug zu publizieren, der sich dann als falsch herausstellt
- Denn wenn Wissenschaftler einen Effekt (signifikante Abweichung von Nullhypothese) beobachten, möchten sie sicher sein, dass es sich nicht bloss um Zufall handelt
- Fehler 1. Art soll vermieden werden
- Nimmt in Kauf, dass man manchmal wichtigen Effekt verpasst
- Fehler 2. Art ist also zweitrangig

- Fehler 1. Art wird direkt kontrolliert durch Konstruktion eines Tests, indem Signifikanzniveau  $\alpha$  möglichst klein gehalten wird
- Über die W'keit eines Fehlers 2. Art keine solche Kontrolle
- Die beiden Fehlerarten konkurrenzieren sich gegenseitig:  
 $P(\text{Fehler 2. Art})$  wird grösser falls  $\alpha$  kleiner gewählt wird
- Wahl von  $\alpha$  steuert Kompromiss zwischen Fehler 1. und 2. Art
- Weil man aber primär einen Fehler 1. Art vermeiden will, wählt man  $\alpha$  klein, z.B.  $\alpha = 0.05$
- Je kleiner  $\alpha$ , desto kleiner der Verwerfungsbereich
- Vertikale Linie wandert nach rechts  $\rightarrow$  Fehler 2. Art wird umso grösser




# Wahl von Signifikanzniveau $\alpha$


- Graphik:  $\alpha = 0.0001$  (nahe bei 0)



- Graphik:  $\alpha = 0.8$  (gross)



- Graphik:  $\alpha = 0.05$



- Ist  $\alpha$  sehr nahe bei null, so Bereich wo *nicht* verworfen wird (grüner Bereich) sehr gross
- D.h.: Es braucht ein sehr Ereignis bis verworfen wird
- Es wird viel zu wenig verworfen
- Im Extremfall  $\alpha = 0$ : Es wird gar nicht verworfen
- Für  $\alpha$  gross: Grüner Bereich sehr klein
- D.h.: Es braucht ein sehr Ereignis bis verworfen wird
- Es wird viel zu wenig verworfen
- Im Extremfall  $\alpha = 1$ : Es wird immer verworfen
- $\alpha = 0.05$ : Kompromiss zwischen den beiden Extremen

# Vertrauensintervalle für Normalverteilungen: Einleitung

- Betrachten nochmals Verwerfungsbereich einer normalverteilten Zufallsvariable  $X$  mit bekannten  $\sigma_X$
- Beschränkung vorläufig auf Signifikanzniveau 5 % und zweiseitigem Verwerfungsbereich
- Siehe Jupyter Notebook: `vertrauensintervall_py` (durchmachen)

# Vertrauensintervall allgemein

- Das sogenannte *Vertrauensintervall* bei Messdaten besteht aus denjenigen Werten  $\mu$ , bei denen der entsprechende Test nicht verwirft
- Das sind also alle Parameterwerte des Zufallsmodells, bei denen die Daten recht wahrscheinlich oder plausibel sind
- Dieses Intervall enthält dann das wahre, aber meist unbekannte  $\mu$  mit einer gegebenen Wahrscheinlichkeit
- Z.B. ist das 95 %-Vertrauensintervall für  $\mu$  das Intervall, das  $\mu$  mit einer Wahrscheinlichkeit von 0.95 enthält
- D.h. wenn wir sehr viele Testreihen machen und jeweils das Vertrauensintervall bestimmen, so wird  $\mu$  in 95 % dieser Intervalle enthalten sein
- Ist das Signifikanzniveau  $\alpha$ , so ist nennen wir das Intervall  $(1 - \alpha) \cdot 100$  %-Vertrauensintervall.

# Vertrauensintervalle für $\mu$ einer Messreihe

- Gehen nun wieder von *Messreihen* aus
- Annahme: Daten Realisierungen von

$$X_1, \dots, X_n \text{ i.i.d. } \sim \mathcal{N}(\mu, \sigma_X^2)$$

- Müssen wieder unterscheiden, ob  $\sigma_X$  bekannt oder unbekannt ist

# Vertrauensintervalle, falls $\sigma_X$ bekannt

- Diesen Fall schon in Einleitung betrachtet
- Der Mittelwert  $\bar{X}_n$  folgt der Verteilung

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \sigma_{\bar{X}_n}^2\right) = \mathcal{N}\left(\mu, \frac{\sigma_X^2}{n}\right)$$

## Beispiel

- Schmelzwärme von früher: Normalverteilt mit  $\mu = 80$  und  $\sigma_X = 0.02$
- Standardabweichung wird hier also als bekannt angenommen
- Mittelwert:  $\bar{x}_{13} = 80.02$
- Zweiseitige Vertrauensintervall für Methode A:

$$I = [80.009, 80.031]$$

```
from scipy.stats import norm, t
import numpy as np

norm.interval(alpha=0.95, loc=80.02, scale=0.02/np.sqrt(13))
## (80.00912807593181, 80.03087192406818)
```

- Insbesondere liegt 80.00 nicht im Intervall  $I$
- Wert  $\mu = 80.00$  ist folglich nicht mit den Daten kompatibel

# Vertrauensintervalle, falls $\sigma_X$ unbekannt

- Ist  $\sigma_X$  unbekannt, so verwenden wir  $t$ -Verteilungen und die geschätzte Standardabweichung  $\hat{\sigma}_X$
- Normalverteilung durch  $t$ -Verteilung mit Freiheitsgrad  $n - 1$  ersetzen.



# Schmelzwärme Methode A

- Die Standardabweichung lautet

$$\hat{\sigma}_X = 0.024$$

- Zweiseitige Konfidenzintervall für die mit Methode A gemessene Schmelzwärme:

```
import scipy.stats as st
from scipy.stats import norm, t
import numpy as np

t.interval(alpha=0.95, df=12, loc=80.02, scale=0.024/np.sqrt(13))
## (80.00549694515017, 80.03450305484982)
```

$$I = [80.01, 80.03]$$

- Insbesondere liegt 80.00 nicht im Intervall  $I$
- Der Wert  $\mu = 80.00$  ist folglich nicht mit den Daten kompatibel, was wir bereits mit Hilfe des  $t$ -Tests ermittelt hatten.